



Машинное обучение, ШАД

Занятие 4



Доверительные интервалы и статистические критерии

Материал по рассказан по доске



Два вспомогательных распределения



Распределение хи-квадрат

Обозначение: χ_k^2 — хи-квадрат с k степенями свободы

- ▶ Параметр k — кол-во степеней свободы;
- ▶ Плотность

$$p(x) = \frac{1}{2^{k/2}\Gamma(k/2)} x^{k/2-1} e^{-x/2};$$

- ▶ $\chi_k^2 = \Gamma(1/2, k/2)$;
- ▶ Если ξ_1, \dots, ξ_k — независимые $\mathcal{N}(0, 1)$,
то $\xi_1^2 + \dots + \xi_k^2 \sim \chi_k^2$;
- ▶ Если $\eta \sim \chi_k^2$, то $E\eta = k, D\eta = 2k$;
- ▶ $\chi_{k,p}^2$ — p -квантиль распределения χ_k^2 .
- ▶ `scipy.stats.chi2(df=k)`





Распределение Стьюдента

Обозначение: T_k — распределение Стьюдента с k степенями свободы


- ▶ Параметр k — кол-во степеней свободы;
- ▶ T_1 — распределение Коши
- ▶ $T_\infty = \mathcal{N}(0, 1)$
- ▶ Плотность

$$p(x) = \frac{\Gamma(\frac{k+1}{2})}{\sqrt{\pi k} \Gamma(k/2)} \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}};$$

- ▶ Если $\xi \sim \mathcal{N}(0, 1)$ и $\eta \sim \chi_k^2$ независимы, то $\zeta = \frac{\xi}{\sqrt{\eta/k}} \sim T_k$
- ▶ Если $\zeta \sim T_k$, то $E\zeta = 0$ при $k > 1$
- ▶ Если $\zeta \sim T_k$, то $D\zeta = \frac{k}{k-2}$ при $k > 2$
- ▶ $T_{k,p}$ — p -квантиль распределения T_k
- ▶ `scipy.stats.t(df=k)`



Сравнение распределений




Распределение Стюдента похоже на нормальное, но обладает более тяжелыми хвостами, т.е. плотность медленнее убывает при $x \rightarrow \infty$.

Уильям Сили Госсет

Работал на пивоваренном заводе
Гиннеса в Дублине.

Чтобы предотвратить раскрытие
конфиденциальной информации, Гиннесс
запретил своим работникам публикацию
любых материалов, независимо
от содержащейся в них информации.

Госсет выбрал себе псевдоним Student.





Стат. свойства линейной регрессии



Модель линейной регрессии *(повторение)*

Рассматриваем функциональную зависимость вида

$$y = y(x) = \theta_1 x_1 + \dots + \theta_d x_d,$$

x_1, \dots, x_d — признаки,

$\theta = (\theta_1, \dots, \theta_d)^T$ — вектор параметров.

Предполагается, что данные удовлетворяют соотношению

$$Y_i = y(x_i) + \varepsilon_i = \theta_1 x_{i1} + \dots + \theta_d x_{id} + \varepsilon_i, \quad i = 1, \dots, n,$$

$x_i = (x_{i1}, \dots, x_{id})$ — признаковые описания объекта i

обычно неслучайные,

ε_i — случайная ошибка измерений.



Модель линейной регрессии (повторение)

Введем обозначения

$$Y = \begin{pmatrix} Y_1 \\ \dots \\ Y_n \end{pmatrix}, \quad X = \begin{pmatrix} x_{11} & \dots & x_{1d} \\ \dots & & \\ x_{n1} & \dots & x_{nd} \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \dots \\ \varepsilon_n \end{pmatrix}.$$

Матричная форма записи данных

$$Y = X\theta + \varepsilon.$$

$X \in \mathbb{R}^{n \times d}$ — регрессоры или матрица признаков,

$Y \in \mathbb{R}^n$ — отклик.

Матричный вид зависимости: $y(x) = x^T \theta$.



Метод наименьших квадратов (повторение)

Задача: $\|Y - X\theta\|_2^2 \rightarrow \min_{\theta \in \mathbb{R}^d}$.

Решение: $\hat{\theta} = (X^T X)^{-1} X^T Y$ если $\text{rank } X = d$.

Предсказания: $\hat{y}(x) = x^T \hat{\theta}$.

Предположения и следствия:

1. $E\varepsilon = 0$ — несмещенность:

- ▶ $\hat{\theta}$ — несмещенная оценка θ ,
- ▶ $\hat{y}(x)$ — несмещенная оценка $y(x)$.

2. $E\varepsilon = 0$ и $D\varepsilon = \sigma^2 I_n$ — несмещенность и гомоскедастичность:

- ▶ $D\hat{\theta} = \sigma^2 (X^T X)^{-1}$, $D\hat{y}(x) = \sigma^2 x^T (X^T X)^{-1} x$;
- ▶ $\hat{\sigma}^2 = \frac{1}{n-d} \|Y - X\hat{\theta}\|_2^2$ — несмещенная оценка σ^2 .

3. $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ — гауссовская линейная модель:

- ▶ МНК совпадает с ОМП для θ .



Доверительные интервалы при $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$

Величина	Интервал
σ	$\left(\sqrt{\ Y - X\hat{\theta}\ ^2 / \chi_{n-d, \frac{1+\alpha}{2}}^2}, \sqrt{\ Y - X\hat{\theta}\ ^2 / \chi_{n-d, \frac{1-\alpha}{2}}^2} \right)$
Дов. интервал для размера шума в отклике	
θ_j	$\left(\hat{\theta}_j \pm T_{n-d, \frac{1+\alpha}{2}} \cdot \hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}} \right)$
Дов. интервал для коэффициента перед j -м признаком	
$x_0^T \theta$	$\left(x_0^T \hat{\theta} \pm T_{n-d, \frac{1+\alpha}{2}} \cdot \hat{\sigma} \sqrt{x_0^T (X^T X)^{-1} x_0} \right)$
Дов. интервал для среднего отклика на объекте x_0	
$x_0^T \theta + \varepsilon$	$\left(x_0^T \hat{\theta} \pm T_{n-d, \frac{1+\alpha}{2}} \cdot \hat{\sigma} \sqrt{\mathbf{1} + x_0^T (X^T X)^{-1} x_0} \right)$
Предск. интервал для наблюдаемого отклика на объекте x_0	

Число α — уровень доверия, обычно $\alpha = 0.95$



Значим ли признак x_j ?

Гипотеза о **незначимости** коэффициента θ_j

$$H_0: \theta_j = 0 \quad \text{vs.} \quad H_1: \theta_j \{<, \neq, >\} 0$$

Критерий Стьюдента (t-test)

$$T_j(X, Y) = \frac{\hat{\theta}_j}{\hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}}} \stackrel{H_0}{\sim} T_{n-d},$$

где $T_j(X, Y)$ — t-статистика критерия.

Для $H_1: \theta_j \neq 0$ критерий имеет вид $\left\{ |T_j(X, y)| > T_{n-d, \frac{1-\alpha}{2}} \right\}$,

где число α — уровень значимости, обычно $\alpha = 0.05$.

Если H_0 не отвергается, то можно считать, что θ_j отклоняется от нуля статистически незначимо.



Пример: *AB-тест*

Пользователи делятся случайно на две независимые группы:

1. *Контрольная группа A* — использует **старую** ML-модель;
 $Y_1 = (Y_{11}, \dots, Y_{n1})$, $EY_{i1} = a$ — результаты.
2. *Исследуемая группа B* — использует **новую** ML-модель;
 $Y_2 = (Y_{12}, \dots, Y_{m2})$, $EY_{i2} = b$ — результаты.

Что может быть результатом?

- ▶ Сумма покупки.
- ▶ Клик по рекламе.
- ▶ Длина сессии.
- ▶ Регистрация пользователя на сервисе.
- ▶ и т.д.

Гипотезы:

$H_0: a = b$ — отсутствие эффекта,

$H_1: a \neq b$ — эффект присутствует.



Сведем линейной регрессии

Введем обозначения

$$Y = \begin{pmatrix} Y_{11} \\ \dots \\ Y_{n1} \\ Y_{12} \\ \dots \\ Y_{m2} \end{pmatrix}, \quad X = \begin{pmatrix} 1 & 0 \\ \dots & \dots \\ 1 & 0 \\ 1 & 1 \\ \dots & \dots \\ 1 & 1 \end{pmatrix}, \quad \theta = \begin{pmatrix} \theta_0 \\ \theta_1 \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \dots \\ \varepsilon_{n+m} \end{pmatrix}.$$

Линейная регрессия предполагает зависимость $Y = X\theta + \varepsilon$.

Тогда $Y_{i1} = \theta_0 + \varepsilon_i$ и $Y_{i2} = \theta_0 + \theta_1 + \varepsilon_{n+i}$, следовательно

- ▶ θ_0 — среднее в группе А,
- ▶ θ_1 — **эффект от эксперимента**.

Вывод: для проверки АВ-теста нужно построить интервал для θ_1 и проверить гипотезу $H_0: \theta_1 = 0$ критерием Стьюдента.



Учет признаков: аналог CUPED в АВ-тестах

Если есть дополнительные признаки, например, сумма прошлых покупок, возраст пользователя, его пол, можно учесть эти признаки

$$Y = \begin{pmatrix} Y_{11} \\ \dots \\ Y_{n1} \\ Y_{12} \\ \dots \\ Y_{m2} \end{pmatrix}, \quad X = \begin{pmatrix} 1 & 0 & \vec{x}_{11} \\ \dots & & \\ 1 & 0 & \vec{x}_{n1} \\ 1 & 1 & \vec{x}_{12} \\ \dots & & \\ 1 & 1 & \vec{x}_{m2} \end{pmatrix}, \quad \theta = \begin{pmatrix} \theta_0 \\ \theta_1 \\ \vec{\theta}_2 \end{pmatrix}, \quad \varepsilon = \begin{pmatrix} \varepsilon_1 \\ \dots \\ \varepsilon_{n+m} \end{pmatrix}.$$

Линейная регрессия предполагает зависимость $Y = X\theta + \varepsilon$.

Тогда $Y_{i1} = \theta_0 + \vec{x}_{i1}^T \vec{\theta}_2 + \varepsilon_i$ и $Y_{i2} = \theta_0 + \theta_1 + \vec{x}_{i1}^T \vec{\theta}_2 + \varepsilon_{n+i}$, след.

- ▶ θ_0 — среднее в группе А,
- ▶ θ_1 — **эффект от эксперимента**
при фиксированных остальных факторах.

Вывод: для проверки АВ-теста нужно построить интервал для θ_1 и проверить гипотезу $H_0: \theta_1 = 0$ критерием Стьюдента.



Гетероскедастичность и анализ остатков



Остатки

$D\varepsilon = \sigma^2 I_n$ — гомоскедастичность. Обратное — гетероскедастичность.

В качестве оценки ошибки ε_i рассмотрим остатки $e_i = Y_i - \hat{Y}_i$

Проблема: $D e_i \neq \sigma^2$ при гомоскедастичности. Покажем это.

Вектор остатков $e = Y - \hat{Y} = (I_n - H)Y$, где $H = X(X^T X)^{-1} X^T$;

$$De = (I_n - H)DY(I_n - H)^T = \sigma^2(I_n - H)(I_n - H)^T = \sigma^2(I_n - H),$$

$$\text{где } HH^T = X(X^T X)^{-1} X^T X(X^T X)^{-1} X^T = X(X^T X)^{-1} X^T = H.$$


Проверять на однородность дисп. нужно **поправленные остатки**:

$$\hat{e}_i = \frac{e_i}{\sqrt{D e_i}} = \frac{e_i}{\sqrt{\frac{\|Y - X\hat{\theta}\|^2}{n-d} (1 - H_{ii})}} \text{ — студентизированные остатки}$$




Визуальный анализ

Строятся графики зависимости \hat{e}_i от y, x, i




Признак

Все хорошо



Предсказание

Есть выбросы



Остатки


Признак

Нужно добавить x^2



Признак


Гетероскедастичность



Остатки

Номер наблюдения

Тренд




Остатки

Признак


Неправильная модель

Визуальный анализ


Что будет если строить графики зависимостей таргета от признаков:



Признак 1



Признак 2




Признак 1


Гетероскедастичность?

Гетероскедастичность?

Признаки зависимы




Признак 1



Признак 2

Нет, все хорошо!



Что делать при гетероскедастичности?

- ▶ Если нужна только оценка θ — ничего;
- ▶ Если есть предположения о природе гетероскедастичности, взвесить наблюдения:

$$Y_i / \hat{\sigma}_i = (x_i / \hat{\sigma}_i)^T \theta + \varepsilon_i,$$

где $\hat{\sigma}_i$ — предполагаемая дисперсия при i -м измерении;

- ▶ Преобразование признаков и отклика, напр., Бокса-Кокса:

$$Z_i = \begin{cases} \ln Y_i, & \lambda = 0 \\ (Y_i^\lambda - 1)/\lambda, & \lambda \neq 0 \end{cases}$$

Величина λ подбирается по графику зависимости MSE от λ

- ▶ Использовать специальные оценки дисперсии, устойчивые к гетероскедастичности.



Устойчивые оценки дисперсии

Пусть $E\varepsilon = 0$ и $D\varepsilon = V$.

Тогда $\Sigma = D\hat{\theta} = (X^T X)^{-1} X^T V X (X^T X)^{-1}$.

1. $V = \sigma^2 I_n$ — гомоскедастичность:

$\Sigma = \sigma^2 (X^T X)^{-1}$ — дисперсия оценки коэффициентов;

$\hat{\Sigma} = \hat{\sigma}^2 (X^T X)^{-1}$ — оценка дисперсии оценки коэффициентов;

2. $V = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$ — отсутствие автокорреляций:

$\Sigma = (X^T X)^{-1} X^T \cdot \text{diag}(\sigma_1^2, \dots, \sigma_n^2) \cdot X (X^T X)^{-1}$ — д.о.к.;

$\hat{\Sigma} = (X^T X)^{-1} X^T \cdot \text{diag}(\hat{\sigma}_1^2, \dots, \hat{\sigma}_n^2) \cdot X (X^T X)^{-1}$ — о.д.о.к..

3. Наличие автокорреляций — более сложный случай,

при котором зависимы элементы выборки.

Используются кластерное представление ковариационной матрицы или модели временных рядов.



Устойчивые оценки дисперсии

Если автокорреляции отсутствуют, используются **оценка Уайта**
White's heteroscedasticity-consistent estimator (HCE)

$$\hat{\Sigma} = (X^T X)^{-1} X^T \cdot \text{diag}(\hat{\sigma}_1^2, \dots, \hat{\sigma}_n^2) \cdot X (X^T X)^{-1}$$

Варианты определения $\hat{\sigma}_i^2$

1. HC0: \hat{e}_i^2 — оценка Уайта
2. Модификации МакКиннона-Уайта

$$\text{HC1: } \frac{n}{n-d} \hat{e}_i^2, \quad \text{HC2: } \frac{\hat{e}_i^2}{1 - H_{ii}}, \quad \text{HC3: } \frac{\hat{e}_i^2}{(1 - H_{ii})^2}$$

Точнее оценивают при малых выборках.



Как ее применять?

Если автокорреляции отсутствуют, то выполнена асимптотическая нормальность оценки коэффициентов

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}(0, B),$$

НСЕ дает хорошую (состоятельную) оценку на матрицу B :

$$n\hat{\Sigma} \xrightarrow{P} B$$

Данный факт позволяет строить асимптотические дов. интервалы для коэффициентов моделей и таргета, а также критерий Вальда для проверки линейных гипотез $H_0: T\theta = \tau$.



Обобщенная модель линейной регрессии



Вспомним простую линейную регрессию с норм. шумом

Данные $Y = X\theta + \varepsilon \sim \mathcal{N}(X\theta, \sigma^2 I_n)$

Строим модель вида $y(x) = x^T \theta$.

Что мы предсказываем?

Пусть x_0 новый объект.

Тогда $Y_0 = x_0^T \theta + \varepsilon_0 \sim \mathcal{N}(x_0^T \theta, \sigma^2)$.

Т.е. в качестве предсказания оцениваем $E Y_0$ — *ожидаемый отклик*.

Итог

$y \in \mathbb{R}$ — значения наблюдаемого отклика

$E_x Y$ — ожидаемый отклик

$Y_i \sim \mathcal{N}(x_i^T \theta, \sigma^2)$ — наблюдаемый отклик



Пуассоновское распределение

$$\text{Pois}(\lambda) : p(x) = \frac{\lambda^x}{x!} e^{-\lambda}, x \in \mathbb{Z}_+$$

Смысл: число событий,
произошедших за единицу времени


Условия:

1. события происходят с фиксированной интенсивностью λ .
2. независимо друг от друга.

Утверждение: время между двумя событиями имеет распр. $\text{Exp}(\lambda)$

Примеры:

1. число клиентов в час
2. число запросов на сервер за минуту





События разной интенсивности

Интенсивность может зависеть от каких-то факторов.

X_1, \dots, X_n — факторы интервала времени

Y_1, \dots, Y_n — число событий, произошедших за интервал времени

Тем самым имеется $\lambda(x)$ — интенсивность событий для факторов x .

Получаем $Y_i \sim \text{Pois}(\lambda(x_i))$

Что предсказывать?

Нет смысла предсказывать сам Y_i ,

т.к. помимо $\lambda(x_i)$ он содержит непрогнозируемый шум.

Тогда оценим $EY_i = \lambda(x_i)$ — *ожидаемый отклик*.

Как параметризовать $\lambda(x)$ для *линейной* модели?



Определимся с требованиями

Пусть значению $x_0^T \theta = 0$ соответствует интенсивность $\lambda_0 = 1$.

Значению $x_1^T \theta$ сопоставим интенсивность $\lambda_1 = 5$ событий в час.

Хотим чтобы значению $-x_1^T \theta$ соответствовала интенсивность $1/\lambda_1 = 0.2$ событий в час.

Линеаризация

Соответственно, нужно взять $\lambda_\theta(x) = \exp(x^T \theta)$.

Тогда $\ln \lambda_\theta(x) = x^T \theta$.

$g(z) = \ln z$ — **линеаризация** ожидаемого отклика.

Итог

$y \in \mathbb{Z}_+$ — значения наблюдаемого отклика

$\lambda_\theta(x) = E_x Y$ — ожидаемый отклик

$Y_i \sim \text{Pois}(\lambda_\theta(x_i))$ — наблюдаемый отклик

Это **пуассоновская регрессия**.



Случай бинарной классификации

X_1, \dots, X_n — признаки объекта

Y_1, \dots, Y_n — бинарный класс

Тем самым имеется $\rho(x)$ — вероятность класса 1 для объекта x .

Получаем $Y_i \sim \text{Bern}(\rho(x_i))$

Что предсказывать?

Оцениваем $EY = \rho(x)$ — *ожидаемый отклик*.

Как параметризовать $\rho(x)$ для *линейной модели*?



Определимся с требованиями

Пусть значению $x_0^T \theta = 0$ соответствует вероятность 0.5.

Значению $x_1^T \theta$ сопоставим вероятность $\rho_0 = 0.9$.

Хотим чтобы значению $-x_1^T \theta$ соответствовала вероятность 0.1.

Что такое в 2 раза более/менее вероятно?

Возможно, 0.95 и 0.05, но это не точно.

Сведение к параметру масштаба

Заметим, что $\frac{\rho}{1-\rho}$ — насколько чаще выпадает класс 1 по сравнению с классом 0. Тем самым это параметр масштаба.

Линеаризация

Логит $g(z) = \ln \frac{z}{1-z}$ — линеаризация ожидаемого отклика.

Т.е. параметризация $\rho_\theta(x)$ должна быть такой, что $\ln \frac{\rho_\theta(x)}{1-\rho_\theta(x)} = x^T \theta$.

Тогда нужно взять $\rho_\theta(x) = \frac{1}{1+\exp(-x^T \theta)}$.


Бинарный отклик

$y \in \{0, 1\}$ — значения наблюдаемого отклика

$\rho_{\theta}(x) = P_x(Y = 1)$ — ожидаемый отклик

$Y_i \sim \text{Bern}(\rho_{\theta}(x_i))$ — наблюдаемый отклик

Это **логистическая регрессия**.





Обобщенная модель линейной регрессии

Гауссовская линейная модель

Ожидаемый отклик:

$$y = \mu_{\theta}(x) = x^T \theta.$$

Наблюдаемый отклик:

$$Y_i = x_i^T \theta + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2).$$

$$\text{или } Y_i \sim \mathcal{N}(\mu_{\theta}(x_i), \sigma^2)$$

Оценка отклика:

$$\hat{y} = x^T \hat{\theta}.$$

Generalized Linear Models (GLM)

Ожидаемый отклик:

$$y = \mu_{\theta}(x), \text{ причем } g(\mu_{\theta}(x)) = x^T \theta,$$

т.е. g — линейризация ожид. отклика

Наблюдаемый отклик:

$$Y_i \sim P_{\mu_{\theta}(x_i)},$$

где $\{P_{\psi} \mid \psi \in \Psi\}$ — семейство распр.

Оценка отклика:

$$\hat{y} = g^{-1} \left(x^T \hat{\theta} \right).$$



Свойства GLM

В качестве $\hat{\theta}$ берется ОМП (ищется численно)

$$L_X(\theta) = \prod_{i=1}^n p_{\mu_\theta(x_i)}(Y_i) = \prod_{i=1}^n p_{g^{-1}(x_i^T \theta)}(Y_i) \rightarrow \max_{\theta}$$

Если $\{P_\psi \mid \psi \in \Psi\}$ лежит в экспоненциальном классе, то $\hat{\theta}$:

1. существует и единственна;
2. асимптотически нормальна: $\sqrt{I(\theta)} (\hat{\theta} - \theta) \xrightarrow{d} \mathcal{N}(0, I_d)$,
где $I(\theta) = \left(-E \frac{\partial^2 \log L_X(\theta)}{\partial \theta_j \partial \theta_k} \right)_{jk}$ — информационная матрица Фишера.

Частные случаи:

1. Линейная (гауссовская): $I(\theta) = \sigma^{-2} X^T X$.
2. Логистическая: $I(\theta) = X^T \cdot \text{diag} [\sigma(x_i^T \theta) (1 - \sigma(x_i^T \theta))] \cdot X$.
3. Пуассоновская: $I(\theta) = X^T \cdot \text{diag} [\exp(x_i^T \theta)] \cdot X$.

Примечание. Свойства работают если верны предположения модели.



Асимпт. доверительные интервалы в GLM

Для параметров (\implies критерий для гипотезы $H_0: \theta_j = 0$)

$$\theta_j \in \left(\hat{\theta}_j \pm z_{1-\alpha/2} \sqrt{\left(I^{-1}(\hat{\theta}) \right)_{jj}} \right)$$

Для преобразованного ожидаемого отклика

$$x_0^T \theta \in \left(x_0^T \hat{\theta} - \delta, x_0^T \hat{\theta} + \delta \right)$$

Для ожидаемого отклика

$$\mu(x_0) = g^{-1}(x_0^T \theta) \in \left[g^{-1} \left(x_0^T \hat{\theta} - \delta \right), g^{-1} \left(x_0^T \hat{\theta} + \delta \right) \right],$$

Например, в случае лог. регрессии можем не просто говорить, что вероятность болезни 20%, но и оценивать интервал для нее: вероятность болезни от 16% до 27%.

Обозначения: $\delta = z_{1-\alpha/2} \sqrt{x_0^T I^{-1}(\hat{\theta}) x_0}$, а z_α — α -квантиль $\mathcal{N}(0, 1)$.

Примечание. Для линейной регрессии вместо σ^2 нужно взять ее несмещ. оценку.



ВСЁ!